研究・イノベーション学会　第41回年次学術大会
2026年 11月1日(日)　12:10～（講演番号：2E10)

多様な大規模言語モデルにおける科学技術政策・高等教育政策領域での質問応答能力の測定

高山 正行[A, B]、三内　顕義[A, B, C, D, E, F]、清水　昌平[A, B, C, E, G]

A. 科学技術・学術政策研究所 (NISTEP)
B. 滋賀大学
C. 京都大学
D. 東京大学
E. 理化学研究所
F. 国立情報学研究所
G. 大阪大学

Mail : masayuki-takayama@biwako.shiga-u.ac.jp

本研究の関心・背景

当グループの現在の関心・Research Question

✓ 科学技術・高等教育政策領域（特に、博士課程進学関係）の政策研究で、
どの大規模言語モデル（LLM）が、どの程度”expert”として機能し、
知識駆動的な政策研究への活用・効率化に、どの程度資するのか？

背景

◆ **政策立案・政策研究へのLLM活用への期待**

- 本学会の講演でも、政策研究での生成AI活用を進めているものは多数

- デジタル庁製生成AI環境「源内」の活用開始など

◆ **実用上、能力を評価する必要**

- 当グループでも、博士人材政策研究での利用可能性を調べるため、
20問でOpenAI社の12モデルを対象とした試行*を実施

＊高山ほか　研究・イノベーション学会　第40回年次学術大会　2B22 (2025)
https://hdl.handle.net/10119/20279

本研究の背景となる技術的課題

政策立案・研究でのLLMの能力評価の技術的課題：

課題1.ベンチマークテストの必要性

課題2.能力評価の方法/あり方

課題3.測定上の課題

課題1: ベンチマークテストの必要性

- LLMの精度は、**様々なベンチマークテスト**で評価
  - 例. MMLU(57分野、14000問以上)
  - 多くの場合、評価効率の観点から、**多肢選択式**
- 政策研究での活用可能性を評価するには、**別途専用のベンチマークテストを一定規模で構築する必要**

例） PolicyBench（Han Bao *et al.* ACL, 2249-2274(2026) https://aclanthology.org/2026.findings-acl.107/）

課題2: 能力評価の方法/あり方

- **問題ごとの特性（難易度等）**を加味した評価（≠ 平均正答率での評価）
- ベンチマークの段階的なアップデートで、解く問題が少しずつ変わっても、**同じ能力軸での評価**

➡ **項目反応理論（IRT）の導入**が少しずつ進められつつある

高山ほか 研究・イノベーション学会 第40回年次学術大会 2B22 (2025)
https://hdl.handle.net/10119/20279

課題3: 測定上の課題

- 通常のIRTは、正解/不正解の2値データからの分析

  ➡ **分析に多くのサンプルサイズを要する**（典型的には10^3のオーダー）

- LLMの**サンプルサイズ※が小さくても、効率的な評価の実現**の必要性

  ※ 基盤モデルで公開され、利用可能なものは、せいぜい10^2のオーダー

  ➡ **選択肢トークンの確率**をAPIで取り出し、連続値データとすることで、**高効率にIRT測定可**

・高山ほか 研究・イノベーション学会 第40回年次学術大会 2B22 (2025)
https://hdl.handle.net/10119/20279
・Fei et al., arXiv, 2026
https://doi.org/10.48550/arXiv.2608.02966

- APIでの確率出力に対応していないLLMも存在（一部のGPT系、Claude、Gemini 等）

  ➡ 比較するには、**正解/不正解の離散データも統合的に評価**する必要

近年の連続/離散の統合IRT分析手法の開発

◆ **当グループにて別途、確率の連続反応データと、正解/不正解の離散反応データを統合して分析する方法を開発**

高山、清水　日本テスト学会　第24回年次大会（2026）

(a)トークン生成確率が一部でも取得可能だった
LLMの確率測定データ（連続的な項目反応確率データ行列）

	Q1	Q2	Q3
LLM1	0.2	0.70	0.9
LLM2	0.55	–	0.98
LLM3	–	0.64	–

APIでトークン生成確率の取り出しが可能で、
正答確率がある程度評価可能なLLM
（項目・LLM次第で、全選択肢のトークン生成確率の和が1に近づかない場合には、(b)のデータで推定。）

+

(b)必要に応じて、LLMの出力を直接評価し、正解回数をカウントしたデータ
（複数回測定による2項分布的・離散的な反応データ行列）

	Q1	Q2	Q3
LLM1	5回中1回正解	5回中4回正解	5回中5回正解
LLM2	5回中3回正解	5回中4回正解	5回中5回正解
LLM3	5回中1回正解	5回中3回正解	5回中4回正解

+

APIでトークン生成確率の取り出しができない、
もしくはLLMの事前学習・インストラクションで、先頭でいきなり選択肢トークンが出力されないLLM

(c)仕様上、トークン生成確率が一切測定ができないなどの事情で、
LLMの出力を直接評価し、正解回数をカウントしたデータ
（複数回測定による2項分布的・離散的な反応データ行列）

	Q1	Q2	Q3
LLM4	5回中1回正解	5回中5回正解	5回中4回正解
LLM5	5回中2回正解	5回中5回正解	5回中5回正解
LLM6	5回中0回正解	5回中4回正解	5回中3回正解

政策立案・研究でのLLMの能力評価の技術的課題：

課題1.ベンチマークテストの必要性 ← **あとはこれを本格化し、評価対象LLMを増やすことで、より着実な評価を実現可能に**

課題2.能力評価の方法/あり方

課題3.測定上の課題

統合IRT分析の手法開発でクリア

本研究の概要・意義

科学技術・高等教育政策領域でのLLMの質問応答能力の測定について、

■ 当グループの過年度の試行から、**問題数/対象LLM数を大幅に増やした大規模実証**を行う

先行研究
・問題数: 20問
・LLM数: 12モデル（OpenAI製のみ）
高山ほか 研究・イノベーション学会 第40回年次学術大会 2B22 (2025)
https://hdl.handle.net/10119/20279

→

本研究
・問題数: 110問
・LLM数: 73モデル
（公開モデルや日本語特化モデル等も含む）

■ 離散的な正解回数データと連続的な正答確率データを**統合的にIRT分析する手法を適用**する

正答確率データ(連続値)
正答回数データ(離散値)
→ **統合IRT分析** →
全てのLLMの科学技術・高等教育政策領域での能力値を同一の評価軸で比較可能な形で推定

■科学技術・高等教育政策の領域での、**問題の種類に応じた項目反応の特徴をIRTで捕捉**する

× この領域で、どのLLMが最も優れているかを図るための測定（どうせ時間経過でランキングは変わる）

○ LLMの能力推定・傾向把握に加え、
各問題の識別力・困難度等も同時に推定し、 継続的なベンチマーク構築・測定に関する知見も得る

実験セットアップ -ベンチマーク構築①

ベンチマーク全体のスペック

- 問題数: 科学技術政策・高等教育政策に関する110問
- 問題作成のベースは、文部科学省や科学技術・学術政策研究所の公表資料
- 5択式で、正解が一意に定まるように作成

問題の分類	問題数
博士人材・博士課程支援	58
大学教員・研究時間　等	20
研究費・競争的資金・間接経費	11
研究大学政策(国際卓越/J-PEAKS)・大学ファンド	10
その他の制度知識	11
合計	110

問題リスト（解答なし）

リンクはこちら

問題作成の具体的な手続き

- 最初の20問は、先行研究*と同じ（問題のみ公開済）

* 高山ほか　研究・イノベーション学会　第40回年次学術大会　2B22 (2025)

- ↑の20問を種問に、文部科学省や科学技術・学術政策研究所の公表資料をもとに、類題案の作成をChatGPTに指示（Few-Shot Prompting）

- 複製された問題について、正解の一意性/客観性/明確性を担保できるよう、著者が問題文・選択肢を書き換え、重複がないように問題セットを構成

実験セットアップ -ベンチマーク構築②

問題例1. 法律・制度に関する理解

令和7年現在、国際卓越研究大学法や科学技術振興機構法に基づき、大学ファンドの運用益によって、国際卓越研究大学でなくとも助成可能な取組として、当てはまるものを一つ選んでください。A～Dに当てはまるものがない場合は、Eを選択してください。
A. 優秀な若年の研究者の育成及び活躍の推進
B. 国際的に卓越した能力を有する研究者の確保、研究の支援または研究成果の活用のために必要な技術者等の確保
C. 研究の支援または研究成果の活用のために必要な技術者等の育成
D. 研究成果の活用のために必要な事業を行うための環境の整備充実
E. A～Dに当てはまるものはない
回答はA、B、C、D、Eのうちアルファベット1文字のみでお願いします。

問題例2. 博士人材施策に関する事実的知識

令和6年度の日本の大学院博士課程入学者数として、以下のうち最も近いものはどれですか。当てはまるものを一つ選んでください。

A. 約0.4万人
B. 約0.8万人
C. 約1.2万人
D. 約1.6万人
E. 2.0万人以上

回答はA、B、C、D、Eのうちアルファベット1文字のみでお願いします。

問題例3. 研究力強化施策に関する事実的知識

J-PEAKSの支援経費のうち、1年間の戦略的実行経費（経費A）の上限として正しいものはどれですか。
当てはまるものを一つ選んでください。A～Dに当てはまるものがない場合は、Eを選択してください。
A. 最大5億円程度
B. 最大10億円程度
C. 最大15億円程度
D. 最大20億円程度
E. A～Dに当てはまるものはない

実験セットアップ –対象となるLLM/測定条件

測定対象のLLMの選定の考え方

- leaderboard等でも高パフォーマンスで知られるLLMの開発元によるLLMで、
  API利用、クラウドGPU活用によるendpointでの利用が可能なものを極力幅広く採用
  -OpenAI, Google, Anthropic, Meta, Qwen, Deepseek, MiniMaxAI,
  Zai, Microsoft, NVIDIA, Mistral AI, Cyberagent, Stockmark, NII(LLM-jp)

- 基盤モデルは、基本的に開発元のinstruction tuningを受けたもののみを使用
  （有志による数学特化fine-tuneを受けたモデルなどは除く）

- ただし、いくつかの主要な日本語特化の訓練を受けたモデルについては、
  日本の政策研究に関する測定であることに鑑み採用

測定条件

- 全て互いに独立に5回反復測定

- 温度パラメータはどのLLMも1.0で固定

- プロンプトは問題文をそのまま打ち込み、
  ・APIで最初のトークンの確率評価が可能な場合には、
  正解選択肢の確率を抽出して、5回の平均値/分散を評価
  ・正答/誤答を直接評価する場合には、出力をそのまま評価し、正解回数を評価
  する形で、データ行列を構成

実験セットアップ –対象となるLLM/測定条件

（参考）測定対象となった全73のLLM（5月の測定時点）

(a)正解確率データ行列のみを取得し、分析にかけたLLM：14種類

cyberagent_calm3-22b-chat
deepseek-ai_DeepSeek-V3
deepseek-ai_DeepSeek-V3.1
deepseek-ai_DeepSeek-V3.2
google_gemma-3-12b-it
google_gemma-3-27b-it
google_gemma-4-31B-it
meta-llama_Llama-3.2-1B-Instruct
meta-llama_Llama-3.3-70B-Instruct
openai_babbage-002
rinna_qwen2.5-bakeneko-32b-instruct
shisa-ai_shisa-v2-llama3.3-70b
stockmark_Stockmark-2-100B-Instruct
tokyotech-llm_Llama-3.3-Swallow-70B-Instruct-v0.4

(b)正解回数データ行列のみを取得し、分析にかけたLLM：26種類

anthropic_claude-haiku-4-5
anthropic_claude-opus-4-7
anthropic_claude-sonnet-4-6
deepseek-ai_DeepSeek-V4-Pro
google_gemini-2.5-pro
google_gemini-3.1-pro
google_gemma-2-2b-jpn-it
MiniMaxAI_MiniMax-M2
MiniMaxAI_MiniMax-M2.7
nvidia_NVIDIA-Nemotron-Nano-9B-v2-Japanese
openai_gpt-5
openai_gpt-5.5
openai_gpt-5-mini
openai_gpt-5-nano
openai_gpt-oss-120b
openai_gpt-oss-20b
openai_o1
openai_o3
o3-mini
o4-mini
Qwen_Qwen3.5-122B-A10B-FP8
Qwen_Qwen3.5-35B-A3B
Qwen_Qwen3.6-35B-A3B
tokyotech-llm_GPT-OSS-Swallow-120B-RL-v0.1
zai-org_GLM-4.6
zai-org_GLM-5.1

(c)正解回数データ行列と確率データ行列の両方を取得し、分析にかけたLLM：33種類

cyberagent_Llama-3.1-70B-Japanese-Instruct-2407
llm-jp-3.1-13b-instruct4
llm-jp-3.1-8x13b-32K-instruct4
llm-jp-3.1-8x13b-instruct4
llm-jp-3-13b-instruct3
llm-jp-3-172b-instruct3
meta-llama_Llama-3.1-70B-Instruct
meta-llama_Llama-3.1-8B-Instruct
microsoft_Phi-3-medium-128k-instruct
microsoft_phi-4
mistralai_Mixtral-8x22B-Instruct-v0.1
openai_gpt-3.5-turbo
openai_gpt-3.5-turbo-0125
openai_gpt-3.5-turbo-1106
openai_gpt-4.1
openai_gpt-4.1-mini
openai_gpt-4.1-nano
openai_gpt-4-0613
openai_gpt-4o
openai_gpt-4o-2024-05-13
openai_gpt-4o-2024-08-06
openai_gpt-4o-mini
openai_gpt-4o-mini-2024-07-18
openai_gpt-4-turbo-2024-04-09
openai_gpt-5.1
openai_gpt-5.2
openai_gpt-5.4
openai_gpt-5.4-mini
openai_gpt-5.4-nano
rinna_gemma-2-baku-2b-it
rinna_llama-3-youko-70b-instruct
shisa-ai_shisa-v2-llama3.1-405b
tokyotech-llm_Gemma-2-Llama-Swallow-27b-it-v0.1

※　11/1時点では、既にshut downされている
　モデルも存在することに注意。

実験セットアップ –統合IRT分析とアルゴリズム

■IRTモデル: 2PL logitを仮定

$$\mu_{i,k}(\theta_i, a_k, b_k) = \frac{1}{1+\exp(-Da_k\,(\theta_i - b_k))}$$

主なパラメータ
- a: 問題の識別力（差のつきやすさ）
- b: 問題の困難度（難しさ）
- θ :LLMの能力値

■正誤（回数）に基づく離散的な反応データ行列での目的関数

ある個体i・項目kで、正誤の反応確率は、$x_{i,k}$=1で正答、$x_{i,k}$=0で誤答として、

$$p(x_{i,k}|\mu_{i,k}(\theta_i, a_k, b_k)) = {\mu_{i,k}}^{x_{i,k}}(1-\mu_{i,k})^{1-x_{i,k}}$$

全測定回数Rに対し、正答回数$r_{i,k}$のとき、データ全体の生成確率$\prod_{i,k} p(x_{i,k}|\mu_{i,k}(\theta_i, a_k, b_k))$の、負の対数尤度$\mathcal{L}_B$は、

$$\mathcal{L}_B = -\sum_{i,k}\left\{r_{i,k}\ln\left(\mu_{i,k}(\theta_i, a_k, b_k)\right) + (R-r_{i,k})\ln\left(1-\mu_{i,k}(\theta_i, a_k, b_k)\right)\right\}$$

■正答確率（分布）に基づく連続的な反応データ行列での目的関数

ある個体i・項目kで、正答選択確率$q_{i,k}$が生成される確率は、正規分布に従うと仮定すると、

$$p\left(q_{i,k}\middle|\mu_{i,k}(\theta_i, a_k, b_k), \sigma_{i,k}\right) = \frac{1}{\sqrt{2\pi{\sigma_{i,k}}^2}}\exp\left(-\frac{(q_{i,k}-\mu_{i,k}(\theta_i, a_k, b_k))^2}{2{\sigma_{i,k}}^2}\right)$$

正答確率データ行列全体の生成確率$\prod_{i,k} p\left(q_{i,k}\middle|\mu_{i,k}(\theta_i, a_k, b_k), \sigma_{i,k}\right)$の負の対数尤度$\mathcal{L}_P$は、定数項を無視し、

$$\mathcal{L}_P = \sum_{i,k}\left\{\frac{1}{2{\sigma_{i,k}}^2}(q_{i,k}-\mu_{i,k}(\theta_i, a_k, b_k))^2\right\}$$

■最適化アルゴリズム

Step 1: θ_i の更新

a_k, b_kを固定した上で、

$$\theta_i^{new} = \arg\min_{\theta_i \in \boldsymbol{R}}(\mathcal{L}_B + \mathcal{L}_P)$$

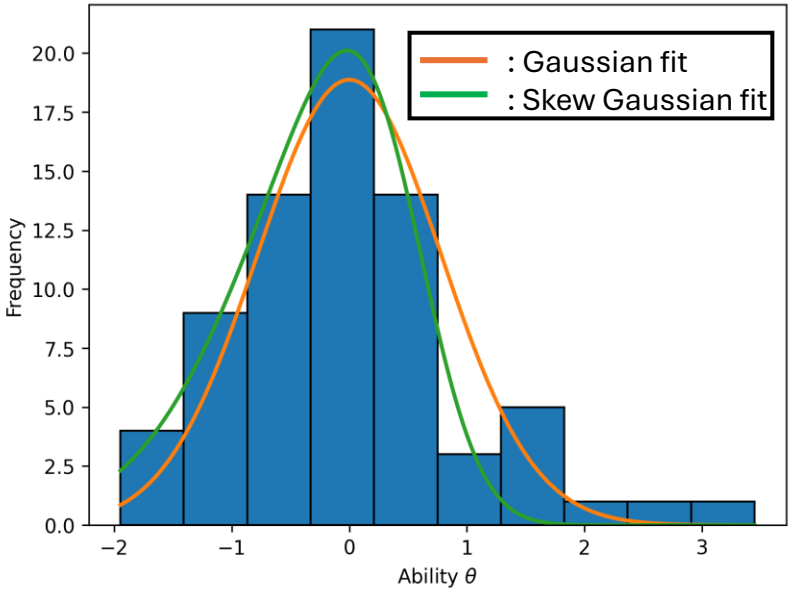
全てのパラメータの収束まで、制約付きで交互最適化

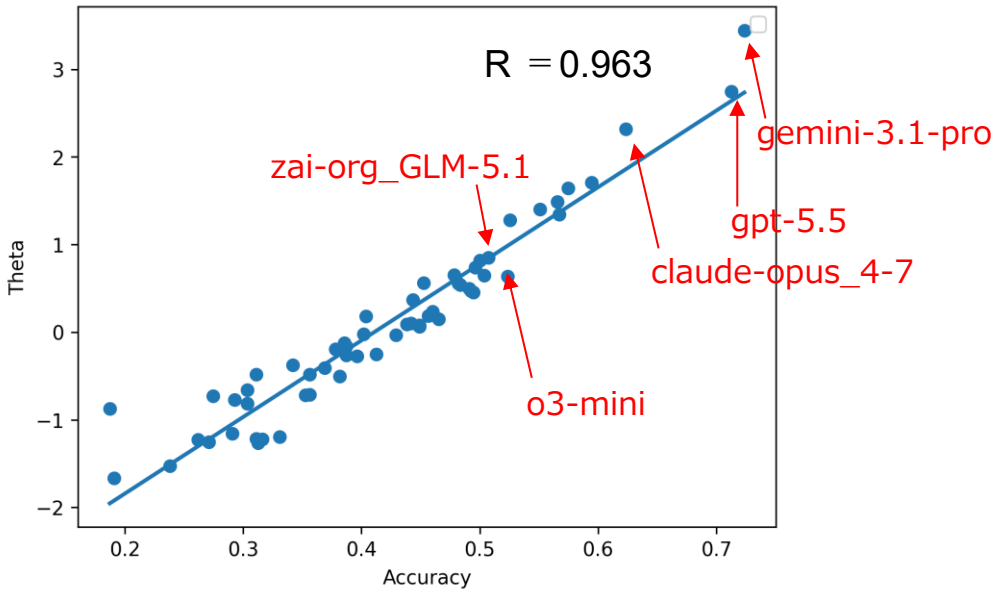
Step 2: a_k, b_k の更新

θ_iを固定した上で、$(a_k^{new}, b_k^{new}) = \arg\min_{a_k>0, b_k \in \boldsymbol{R}}(\mathcal{L}_B + \mathcal{L}_P)$

また、その後、$\{\theta_i^{new}\}$で標準化を実施し、a_k^{new}, b_k^{new}もそのスケールに合わせる。

実験結果・考察 –LLMの能力分布① 全体像





- **分布の特徴:** 今回の測定対象の範囲では、低能力側に偏る傾向

- **平均正答率との相関:** 平均正答率とも強く相関するが、稀に逆転も見られる
  (例. zai-org_GLM-5.1とo3-miniの関係)

- **平均正答率ベースでのスペック確認:** 0.7を超えたのは、gemini-3.1-proとgpt-5.5のみ

- **上位モデルの傾向:** 15位以内に入った公開基盤モデルは、
  ・zai-org_GLM-5.1
  ・deepseek-ai_DeepSeek-V4-Pro
  のみで、残りは、OpenAIやClaude、Geminiなど、
  非公開モデルをベースにUIを提供している各社の比較的新しいモデル

実験結果・考察 –LLMの能力分布② 日本語特化モデルの挙動

基となったモデル	能力推定値		日本語特化モデル	能力推定値
gpt-oss-120b	-0.033（±0.103）	→	tokyotech-llm_GPT-OSS-Swallow-120B-RL-v0.1	+0.455（±0.107）↑
Llama-3.3-70B-Instruct	+0.256（±0.119）	→	shisa-ai_shisa-v2-llama3.3-70b	-0.148（±0.116）↓
Llama-3.1-70B-Instruct	+0.078（±0.086）	→	cyberagent_Llama-3.1-70B-Japanese-Instruct-2407	-0.160（±0.090）↓

■ 日本語特化の訓練 ≠ 文科省/NISTEPの調査・施策・制度の細部まで正確に記憶させること

→ 科学技術・高等教育政策に関する今回のような問題セットでは、
・基盤モデルの総合能力
・ポストトレーニングの質
・選択肢比較能力
が、強く効いている可能性

■ 当該能力の性能向上には、日本語特化のLLMを優先的に採用するか否か以前に、適切な基盤モデルを選択したうえで、
・必要な知識の追加学習
・Retrieval-Augmented Generationや各種検索技術との併用
の検討が望ましい

実験結果・考察 –ベンチマークとした問題の性質① 総論

■全110問の問題の項目パラメータの推定結果の統計値
（全てLLMの能力推定値の分布の標準化のスケールを採用）

指標	平均値	中央値	最小値	最大値
識別力a	0.615	0.407	0.049	4.860
困難度b	1.222	0.786	-5.133	5.156

・識別力 0.5未満の問題数が62問
・困難度の絶対値が4以上の問題（≒難易度が極端なもの）が29問

➡ 測定重視なら、今後の改訂で見直し・差替えが必要か

■識別力の高い問題/低い問題の傾向

識別力の高い問題の例

・FTE調査結果の活用方法として当てはまらないもの
・企業が重視する大学院改革施策
・SPRINGの支援内容として当てはまらないもの
・SPRINGの成果として当てはまらないもの
・博士人材に企業が求める能力・資質
・JSTが担う博士後期課程学生支援事業
・分野に応じた博士課程学生支援制度の対象の考え方として当てはまらないもの
・国際卓越研究大学の要件として当てはまらないもの

✓**当てはまらないものを問う問題**
✓**制度や方法、定性的な特徴・考え方を問うもの**
が多い

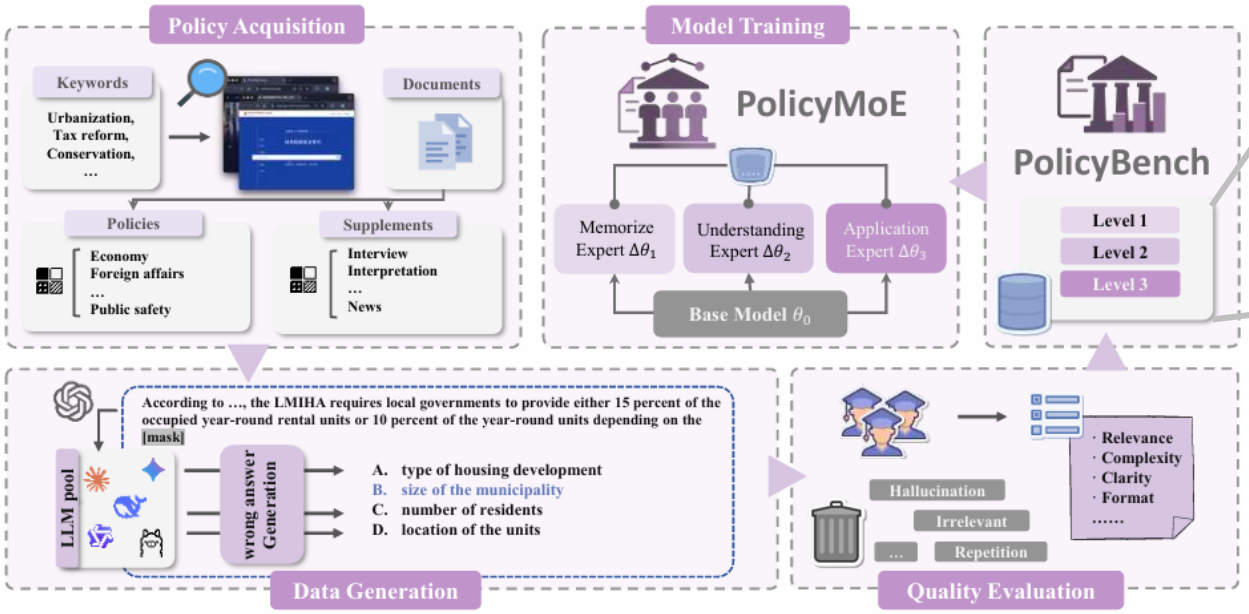
識別力の低い問題の例

・特別研究員（DC）対象者の生活費
・博士課程授業料免除の予算・人数
・ポストドクター等の前職
・経済的支援が給与所得に該当する制度
・ACT-Xの応募資格・制度趣旨として当てはまらないもの
・理工系博士修了者の研究職就職割合
・経済的支援なしの博士課程学生割合

✓**統計調査の数的結果のみを問うもの** が多い
(しかも、多くは困難度が極端に大きい)

実験結果・考察 –ベンチマークとした問題の性質②　先行研究との比較

■ 政策分野でのベンチマーク生成・LLM評価に関する先行研究



Bloom's Taxonomyで分類

- Level 1. Memorization
- Level 2. Understanding
- Level 3. Application

Han Bao *et al.* ACL, 2249-2274(2026)
https://aclanthology.org/2026.findings-acl.107/

✓ 11のLLMでの実験結果：レベルが上がるほど、むしろLLMの正答率が上がる
✓ 解釈: Level 1はLLMのpretrainingでの知識記憶に依存するが、
Level 2～3のような構造化推論はpost-trainingで訓練されるため、LLMが得意になりやすい

対応するLLMの訓練	Baoらによる先行研究（IRTなし、Bloom分類あり）		本研究の傾向（IRTあり、Bloom分類なし）
事前学習	Level 1. Memorization	低正答率傾向	数値的事実を問う項目では、低識別力傾向（困難度も極端に大きいものが多い）
継続学習・事後学習	Level 2. Understanding Level 3. Application	高正答率傾向	制度理解、定性的な特徴・考え方等を問う項目では、高識別力傾向

✓ 政策知識・技能種類により、必要なLLMの訓練も変わり、LLMの応答特性（識別力・困難度）も対応する可能性があり、どう学習させて、政策立案・研究に役立つLLMを構築できるかを深掘りする観点からも、今後検証が期待される

本研究のまとめ

実施した研究内容

■科学技術・高等教育政策領域でのLLMの質問応答能力の測定について、
問題数110/対象LLM数73の大規模実証を実施

■ 離散的な正解回数データと連続的な正答確率データを**統合的にIRT分析する手法を適用**

得られた成果

■**様々なLLMの質問応答能力の測定・比較**を可能とし、問題ごとの性質も定量的に捉えられることを実証

■**日本語特化型のLLMが、必ずしも当該領域で高い性能を示すとは限らない**ことを示し、考察

■**制度・方法や定性的特徴を問う項目では識別力が相対的に高く、
数値的事実・知識を問う項目では低くなる傾向**を示し、考察
➡政策知識・技能種類により、必要なLLMの訓練も変わり、
LLMの応答特性（識別力・困難度）も対応する可能性
（モデル自体の能力だけでなく、その能力を測るベンチマーク項目の測定性能も評価することも重要）

課題・今後の展望

■**ベンチマークの改良**（低識別力、極端な難易度の問題の見直し・差替）

■**モデル選択に関する議論**（2PL logitモデルの妥当性、多次元性の考慮）

■**推定結果の普遍性と政策立案・研究での実用性の判断**
（LLMの多様な測定条件での実験、人間の専門家との共通尺度での比較）